Comparación de utilidad y costo de las acciones y diagnóstico de estabilidad

Informe metodológico de DARL DQN Dummy v4

Proyecto de tesis DARL

Demostración experimental con datos PhysioNet y etiqueta sintética

Corrida auditada: v4, semilla 42

Resumen ejecutivo

- **v4 sí terminó de ejecutarse**, pero su estado es `needs_improvement`: el acuerdo de acciones entre los dos últimos checkpoints fue **85 %**, menor que el umbral de 95 %.
- La variación del retorno de validación sí pasó: **1,47 %** frente al máximo permitido de 5 %.
- El agente entrenó los **1000 episodios** disponibles; aumentar episodios sin diagnosticar la causa no garantiza estabilidad.
- La comparación de políticas favorece acciones distintas según el tipo de cambio: A2 para covariate drift y A3 para concept drift.
- Los signos vitales son reales, pero el objetivo y los cambios de distribución son **sintéticos**. No es una validación clínica.

Lectura principal

Retorno casi constante no implica que el agente repita las mismas acciones. En v4, la puntuación agregada fue estable, pero la política aún cambiaba en parte de las situaciones de validación.

Ficha de datos y alcance

Datos

- Base: registros procesados de PhysioNet/Computing in Cardiology Challenge 2019 [1].
- 1 552 210 filas y 40 336 pacientes en la corrida registrada.
- Entradas: HR, O2Sat, Temp, SBP, MAP, DBP y Resp.
- La etiqueta que aprende XGBoost es `y_dummy` (prevalencia 46,7 %); `SepsisLabel` solo se usa para estratificar particiones.

Diseño de la demostración

- Partición por paciente: A para ajuste inicial; B para entrenamiento, validación y prueba.
- Replay: hasta 200 camas, 16 días simulados; 15 decisiones diarias por escenario y resultado evaluado al día siguiente.
- Escenarios: estable, covariate, concept y combinado.
- Corrida registrada: semilla 42; prueba de una sola semilla.

AUC reportada = ROC-AUC sobre la etiqueta sintética. No representa sensibilidad clínica ni desempeño para diagnosticar sepsis.

Auditoría de los ocho CSV de v4

Archivo	Filas	Comprobación principal
`actions.csv`	420	7 políticas × 4 escenarios × 15 acciones; cero fallbacks y cero diferencias entre solicitada y ejecutada.
`action_audit.csv`	60	4 × 15 decisiones; utilidades completas y regret no negativo.
`calibration.csv`	6	3 velocidades por tipo; covariate 0,25 y concept 0,15 son las velocidades más lentas que califican.
`daily_metrics.csv`	448	7 políticas × 4 × 16 días; AUC completa; 28 recompensas terminales vacías, una por trayectoria.
`drift_dia1_vs_dia16.csv`	2	Resumen descriptivo solo para covariate y concept; no cubre stable ni combined.
`policy_comparison.csv`	28	7 políticas × 4 escenarios; 15 recompensas válidas cada una, sin intervalos de incertidumbre.
`stage_calendar.csv`	64	4 calendarios completos de 16 días; covariate inicia día 5 y concept día 5 o 7 en combined.
`training_history.csv`	1000	100 checkpoints de validación, cada 10 episodios; campos vacíos en episodios sin validación son esperados.

El manifiesto declara 18 rutas gráficas (9 PNG y 9 SVG); en el directorio hay 17 PNG y ningún SVG. Las variantes 04a/b, 05a/b y 07a/b, más las figuras 10–11 del notebook auxiliar, requieren conservar su propia procedencia.

Control de integridad

Los conteos y las ausencias corresponden a la estructura del experimento; no encontré filas duplicadas en la comparación política–escenario ni faltantes en las utilidades de `action_audit.csv`.

Qué mide cada CSV y qué no permite concluir

- `policy_comparison.csv`: compara cada política sobre el replay reservado. `mean_auc` promedia los 16 días observados; el `return` suma 15 recompensas de acción al día siguiente.
- `action_audit.csv`: compara las cuatro acciones desde el mismo pipeline del día y calcula regret inmediato. Es un oracle de un paso, no la política óptima para todo el horizonte.
- `calibration.csv`: selecciona velocidades con tres reglas predefinidas en B-train; no es una evaluación de generalización.
- `drift_dia1_vs_dia16.csv`: el KS compara días con cohortes de pacientes distintas por el recambio del replay; describe el cambio total entre días, no aísla por sí solo el efecto causal de la inyección.
- La corrida usa una sola semilla. Las diferencias de retorno/AUC son observaciones de esta ejecución, no estimaciones con incertidumbre.

Mapa del notebook v4: datos y entorno

Sección / funciones	Qué hace y qué verificar
Configuración; `checkpoint`	Fija semilla, rutas, hiperparámetros, dispositivo y escribe `run_summary.json`.
`find_parquet`	Localiza el parquet y valida columnas, llave paciente–ICULOS y orden temporal.
`split_ids`, `roles`	Divide por paciente y separa roles de actualización y evaluación.
`canonical_scores`, `flip_bit`, `concept_weights`, `concept_threshold`	Construye el objetivo sintético y las trayectorias de relación features–etiqueta.
`make_replay`	Reproduce hasta 200 camas, 100 por rol, y recambia camas al agotar observaciones.
`Pipeline.act`, `auc`, `utility`	Implementa A1–A4, evalúa ROC-AUC y penaliza tiempo normalizado.
`ramp`, `inject`	Aplica covariate drift a vitales y concept drift a `y_dummy`.

Interpretación

Esta primera mitad fabrica el mundo simulado. PhysioNet aporta los registros de signos vitales; el resultado de aprendizaje y ambos cambios son artificiales.

Mapa del notebook v4: señales, agente y evaluación

Sección / funciones	Qué hace y qué verificar
`build_reference`, `psi`, `monitor`	Define referencia por vital y calcula KS, PSI, AUC y saturación antes de actuar.
`encode_observation`	Codifica KS, PSI y AUC en categorías; concatena el historial de tres días (estado de 30 entradas).
`BedEnv.reset`, `_observe`, `step`	Entrega la observación, ejecuta la actualización y revela la AUC del día siguiente.
`QNetwork`, `ReplayBuffer`, `DQNAgent.learn`	Red 30–128–128–4; replay FIFO; objetivo Double DQN, Huber y copia target cada 50 actualizaciones.
`calibrate`	Elige las velocidades más lentas que cumplen umbrales de caída y recuperación en B-train.
`choose_policy`, `roll`	Ejecuta DQN/baselines y, opcionalmente, evalúa el oracle inmediato desde el pipeline actual.
`agreement`, `train_agent`	Valida cada 10 episodios, selecciona checkpoint por media móvil y calcula variación/acuerdo.
`make_figures`, `run_experiment`	Exporta gráficos, CSV y gates; persiste estado de ejecución.

Punto de lectura crítica

`positive_dqn_return` no es un gate informativo: la recompensa suma AUC absoluta menos un costo pequeño, así que un retorno positivo es esperable incluso sin aprender una política superior.

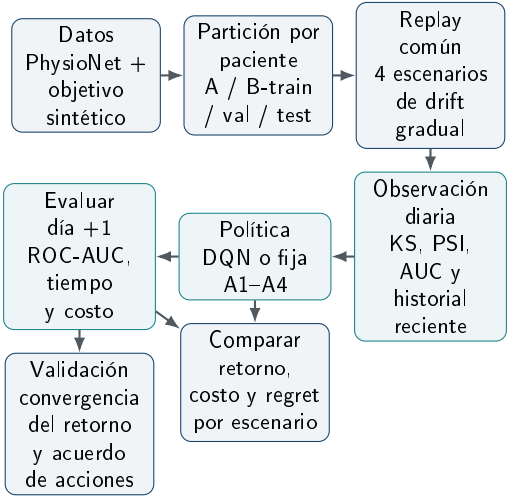
Acciones y justificación de la comparación

Acción	Intervención	Papel experimental
A1	No actualizar el pipeline.	Control de costo mínimo: muestra cuánto se degrada el modelo sin mantenimiento.
A2	Recalibrar mediana/IQR y clipping; conservar XGBoost.	Prueba una intervención sobre la representación, pertinente cuando cambia $P(X)$ y la relación predictiva se mantiene.
A3	Reentrenar XGBoost; conservar el transformador actual.	Prueba una intervención sobre el modelo, pertinente cuando cambia $P(Y \mid X)$.
A4	Actualizar transformador y XGBoost.	Referencia de actualización completa; no es el foco de la tabla, pero sirve para normalizar el costo y contextualizar el máximo de intervención.

Utilidad y costo

El DQN selecciona acciones discretas con una recompensa que penaliza el tiempo de intervención. A1 es un control, A2 y A3 aíslan las dos etapas del pipeline, y A4 permite contrastar el costo de una actualización completa. DQN se basa en Q-learning con aproximación profunda; A1–A4 son intervenciones del diseño y no implican que cada drift requiera una acción única [2, 3].

Flujo propuesto de comparación



Regla de separación: calibrar y seleccionar en B-train/B-val; usar B-test solo para el reporte final. No reajustar hiperparámetros después de mirar el resultado de prueba.

Definición de utilidad y costo

$$r_t = \text{ROC-AUC}_{t+1} - \lambda \frac{T(a_t)}{T_{\text{ref}}}, \qquad \lambda = 0{,}05$$

Donde: r_t es la recompensa al evaluar el día posterior; a_t es la acción tomada; $T(a_t)$ es su tiempo medido; y T_{ref} es el tiempo de referencia de A4 usado para normalizar el costo.

- El retorno de una política es la suma de recompensas válidas en los 15 días evaluables; la media ROC-AUC se reporta aparte.
- Costo de acción normalizado observado en B-train: A1 ≈ 0, A2 $= 0{,}0092$, A3 $= 0{,}0403$, A4 $= 0{,}0500$ por intervención.
- El CSV de comparación acumula el tiempo/costo medidos a lo largo de la política; depende del hardware y de la instrumentación. No equivale a costo monetario ni a costo real de producción.

Políticas fijas: utilidad y costo acumulados

Escenario	Métrica	A1	A2	A3	DQN	Mejor fija	Heurística
Estable	Retorno	14,106	13,906	13,342	14,106	A1 14,106	14,106
	Costo	0,000	0,132	0,639	0,000		0,000
Covariate	Retorno	11,794	13,776	12,606	13,843	A2 13,776	13,807
	Costo	0,000	0,131	0,649	0,097		0,060
Concept	Retorno	11,369	11,052	13,271	13,382	A3 13,271	13,405
	Costo	0,000	0,134	0,628	0,095		0,086
Combinado	Retorno	11,700	11,826	12,556	13,467	A4 13,090	13,422
	Costo	0,000	0,131	0,682	0,164		0,143

- Los costos son acumulados y normalizados del CSV por 15 decisiones; A1 no es costo operacional literalmente nulo.
- A2 lidera entre A1–A3 bajo covariate drift; A3 lidera bajo concept drift. La combinación exige evaluar secuencia y complementariedad.
- En estable, actualizar reduce utilidad y añade costo: el control A1 es la elección razonable.

ROC-AUC media: qué recupera cada intervención

Escenario	A1	A2	A3	DQN	A4	Mejor interpretación
Estable	0,940	0,936	0,932	0,940	0,933	No actuar
Covariate	0,796	0,928	0,887	0,930	0,928	Reajustar features
Concept	0,769	0,758	0,927	0,901	0,927	Reentrenar modelo
Combinado	0,790	0,806	0,886	0,910	0,925	Actualización completa como referencia

Lectura de A1–A3

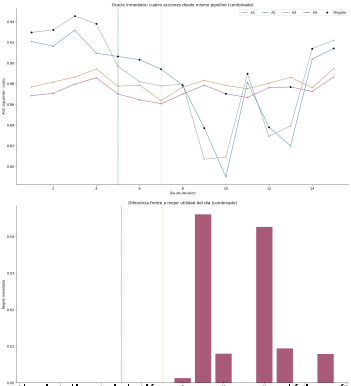
A2 corrige buena parte de la pérdida covariate. En concept, A2 sola no sirve: la señal predictiva requiere actualizar el clasificador (A3).

Límite

En combinado, A4 tiene mayor ROC-AUC media, pero su recompensa neta es inferior a DQN debido a su costo más alto. No comparar AUC aislada con retorno como si fueran la misma métrica.

Auditoría de oportunidades y regret inmediato

- En 60 decisiones de prueba, DQN eligió A1/A2/A3/A4: **38/18/1/3**.
- El oracle inmediato eligió: **35/14/10/1**.
- Coincidencia exacta DQN–oracle: **81,7 %**.
- Regret a no más de 0,01 del oracle en interiores de régimen: **87,5 %**.
- El desajuste más claro es concept: el DQN usa poco A3 frente a las oportunidades inmediatas que lo favorecen.



El oracle evalúa la recompensa de un paso para cada acción desde el pipeline del día; no es una política óptima de horizonte largo.

Oportunidades donde el oracle inmediato prefiere A3

Escenario	Día	DQN	$U(A3)$	U elegida	Regret
Concept	6	A1	0,8783	0,8616	0,0168
Concept	**7**	**A1**	**0,8759**	**0,8101**	**0,0658**
Concept	8	A3	0,8792	0,8792	0,0000
Concept	9	A1	0,8855	0,8745	0,0110
Concept	14	A1	0,8821	0,8564	0,0257
Concept	15	A1	0,8943	0,8523	0,0420
Combined	**9**	**A2**	**0,8832**	**0,8371**	**0,0460**
Combined	10	A4	0,8783	0,8703	0,0080
Combined	12	A2	0,8804	0,8378	0,0426
Combined	**13**	**A4**	**0,8862**	**0,8768**	**0,0094**

Lectura

En la prueba, A3 fue oracle inmediato en 10 días y el DQN la eligió una vez. El regret más alto ocurrió en concept día 7; en combined día 13, elegir A4 quedó a 0,0094 de la utilidad de A3. El oracle es contrafactual de un paso, no una política óptima de horizonte largo.

Tres decisiones: Q, acción y resultado

	Concept, día 7	**Combined, día 9**	**Combined, día 13**
Señales	AUC 0,8616; KS 0,0687; PSI 0,0202	AUC 0,8872; KS 0,2347; PSI 0,1371	AUC 0,8471; KS 0,2590; PSI 0,1511
$Q(A1, A2, A3, A4)$	(1,5023; 1,4581; 1,4218; 1,4546)	(1,1204; 1,1358; 1,0149; 0,8633)	(0,7364; 0,6778; 0,7108; 0,9561)
Acción DQN	A1	A2	A4
AUC siguiente / reward	0,8101 / 0,810063	0,8457 / 0,837144	0,9287 / 0,876802
Oracle A3 / regret	0,875907 / 0,065844	0,883169 / 0,046025	0,886176 / 0,009374

- **Día 7:** AUC sigue en categoría alta ($\geq 0,85$) y KS/PSI están debajo de sus cortes; las categorías no expresan aún el concept activo ($u = 0,45$), aunque A3 habría elevado la utilidad inmediata.
- **Día 9:** las señales medias de covariate favorecen el valor aprendido de A2, pero el oracle de un paso favorece A3.
- **Día 13:** $Q(A4)$ es claramente mayor; la pérdida frente a A3 es pequeña y no implica que la política conozca el oracle.

Disponibilidad temporal: supuesto del entorno

1. Antes de decidir en el día d, `BedEnv._observe(d)` ejecuta `monitor()` sobre la cohorte eval de ese mismo día y construye el estado con KS, PSI y ROC-AUC.
2. La acción usa la cohorte update del día d; después, la recompensa se calcula con ROC-AUC eval del día $d+1$ menos el costo medido.
3. `action_audit.csv` evalúa offline A1–A4 para medir utilidad y regret; esos contrafactuales no se entregan al agente.

Caveat para interpretación

El código expone al monitor la etiqueta sintética de la cohorte eval del día actual antes de la acción; no impone retraso explícito de etiquetas. Es una hipótesis del simulador, no un mecanismo de aprendizaje con etiquetas disponibles solo después. Si la tesis asume retraso clínico, el entorno debe representar ese retraso antes de afirmar que v4 lo respeta.

Por qué falló la estabilidad del 95 %

Dos gates distintos

- Variación relativa del retorno en los últimos cinco checkpoints: **1,47 %**; pasa el límite $\leq 5\,\%$.
- Estabilidad exacta: proporción de acciones idénticas entre los dos últimos checkpoints de validación: **85 %**; no pasa $\geq 95\,\%$.
- La tolerancia de empate Q de 0,005 también dio 85 %: esa tolerancia no explicó las diferencias de acción.

Diagnóstico observable

- La evaluación usa 60 situaciones (4 escenarios $\times$ 15 días): 85 % equivale a unas 51 coincidencias y 9 cambios entre checkpoints.
- El acuerdo fue volátil en el tramo final: 35 % en ep. 960, 38 % en ep. 970, 87 % en ep. 980 y 85 % en ep. 1000.
- Se agotaron los 1000 episodios; no hubo evidencia de convergencia estable al cierre.

Interpretación

El retorno puede variar poco aunque algunas acciones cambien, por compensación entre días/escenarios. La métrica de retorno no certifica que la regla de decisión se haya estabilizado.

Qué sugiere la trayectoria de estabilidad

Evidencia directa

- En checkpoints finales, el acuerdo fue 35 % (ep. 960), 38 % (970), 87 % (980), 83 % (990) y 85 % (1000).
- Ningún acuerdo de checkpoint registrado alcanzó 95 %.
- El retorno cambió poco en conjunto, pero la identidad de las acciones no se asentó.

Explicaciones que deben probarse

- La observación usa categorías discretas de KS/PSI/AUC y tres días de historial: puede ocultar cambios graduales o diferencias entre situaciones.
- El agente aprende sobre escenarios, inicios y velocidades diversos; la mezcla puede producir valores Q cambiantes entre políticas con retornos parecidos.
- El concept drift demanda señal supervisada; el DQN también reaccionó tarde y eligió poco A3 en prueba.

Las dos primeras viñetas de la derecha son hipótesis metodológicas, no causas demostradas por una sola corrida. Se deben contrastar con márgenes Q, acuerdos por escenario y varias semillas.

Una limitación del gate que debe corregirse

- El checkpoint seleccionado para reportar la política fue el **episodio 940**, elegido por media móvil de tres validaciones.
- Sin embargo, el gate final compara las acciones de los **dos últimos checkpoints** (ep. 990 y 1000), no la estabilidad alrededor del checkpoint seleccionado.
- Por tanto, 85 % describe la estabilidad al final del entrenamiento, pero no mide directamente cuánto cambia la política seleccionada en ep. 940 respecto a sus vecinos.
- Esta desalineación no invalida que el gate actual falló; sí limita la interpretación del fallo como inestabilidad del checkpoint que se reportó en prueba.

Conclusión metodológica

Definir primero qué política se desplegará y evaluar estabilidad sobre esa política y checkpoints vecinos. No basta con cambiar el umbral o con aumentar episodios.

Plan para perseguir el 95 % sin sobreajustar

1. **Alinear selección y gate:** congelar una validación; elegir checkpoint con la regla declarada y medir acuerdo antes/después de ese checkpoint, además de retorno.
2. **Exigir persistencia:** registrar acuerdo por escenario y requerir que el gate se mantenga en varios checkpoints consecutivos, no solo en un par aislado.
3. **Diagnosticar cambios:** reportar matriz de transición de acciones y margen entre los dos mayores valores Q; separar cambios en estable, covariate, concept y combinado.
4. **Mejorar señal y cobertura de entrenamiento:** evaluar AUC continua y su tendencia, validez/atraso de etiquetas y tiempo desde la última acción; variar inicios y velocidades de drift en B-train.
5. **Ajustar solo en train/validación:** probar exploración, tasa de aprendizaje, replay y actualizaciones del target. No asumir que más episodios resolverán la inestabilidad: v4 llegó al máximo.
6. **Repetir con varias semillas** y reservar B-test intacto para la evaluación final. Mantener el 95 % como gate preregistrado; no bajar el umbral para declarar éxito.

Cómo cuantificar la meta

Si se mantienen 60 decisiones de validación

Para cumplir 95 % se requieren al menos 57/60 acciones coincidentes. El resultado actual es aproximadamente 51/60; hay que reducir al menos seis desacuerdos en ese conjunto, sin degradar utilidad ni variar la definición del gate.

- No tratar 57/60 como certificado estadístico independiente: las decisiones comparten episodios y estados; repetir semillas y escenarios mide robustez mejor que ampliar solo la misma secuencia.
- Reportar junto al porcentaje: total de estados, acuerdo por escenario, acciones que cambian, diferencias de Q, retorno y regret.
- Un criterio de equivalencia por regret puede complementar el acuerdo exacto, pero debe reportarse por separado; no sustituye el gate del 95 % solicitado.

Conclusiones y trazabilidad

- La utilidad depende del régimen: A2 es la actualización selectiva más eficiente para covariate drift; A3 recupera ante concept drift; A1 evita intervenciones perjudiciales en el escenario estable.
- v4 no superó estabilidad porque el acuerdo exacto final fue 85 %, pese a que la variación del retorno fue baja. La política cambió con frecuencia al final del entrenamiento.
- La selección en ep. 940 y el gate en ep. 990–1000 no están alineados; corregir esa medición es el primer paso antes de nuevas corridas.
- El benchmark usa objetivo sintético, una semilla y costos de tiempo dependientes del entorno: interpretar como prueba de método, no como evidencia clínica o económica.

Fuentes de resultados: `run_summary.json`, `policy_comparison.csv`, `action_audit.csv` y `training_history.csv`, en `kaggle/dqn-dummy/v4/outputs/`. Diseño: `plan/dqn-dummy-v4.md`.

Referencias metodológicas I

- M. A. Reyna et al., "Early Prediction of Sepsis From Clinical Data: The PhysioNet/Computing in Cardiology Challenge 2019," *Critical Care Medicine*, vol. 48, no. 2, pp. 210–217, 2020, doi: 10.1097/CCM.0000000000004145.
- V. Mnih et al., "Human-level control through deep reinforcement learning," *Nature*, vol. 518, pp. 529–533, 2015, doi: 10.1038/nature14236.
- T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.
- H. van Hasselt, A. Guez, and D. Silver, "Deep Reinforcement Learning with Double Q-learning," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 30, no. 1, 2016.

- El target `y_dummy`, el calendario de drift y el replay son construcciones de la demostración v4; no forman parte de PhysioNet ni describen la progresión clínica de sepsis.