

DARL

Aprendizaje por refuerzo con diagnóstico de drift para la actualización selectiva de pipelines tabulares de ML de dos etapas



Jeffrey Antonio Monja Castro · Brigitte Dayane Rojas

Asesora: Ariana Mirella Villegas Suárez | Ciencia de la Computación — UTEC, 2026

Agenda



1. Problemática

Por qué los pipelines se degradan y qué falta en la literatura



2. Objetivos

Pregunta, objetivo general y específicos



3. Diseño de la solución

Pipeline de dos etapas, inyección de drift y agente POMDP



4. Resultados y validación

Avances empíricos y plan de validación



5. Limitaciones y siguientes pasos

Qué falta y cómo lo cerraremos

Los modelos tabulares se degradan cuando cambian los datos

15 / 15

tareas tabulares de TableShift con caída significativa fuera de distribución


18

modelos evaluados; ninguno cierra la brecha de forma consistente

-34.5 %

caída máxima de accuracy (ASSISTments); -22.6 % en crédito (FICO)

Caída de accuracy ID → OOD por tarea (%) — en teal, los datasets de DARL



En salud, esa caída afecta decisiones clínicas



Sepsis en UCI

-6.05 %

de accuracy al pasar de estancias ≤ 47 h a estancias largas [1]

> 60 000 pacientes de UCI, 40 variables clínicas por hora [12]



Readmisión hospitalaria (diabetes)

-5.94 %

de accuracy al cambiar la fuente de admisión a emergencias [1]

10 años de datos de 130 hospitales de EE. UU. [13]

Un modelo de riesgo que se degrada en silencio compromete la asignación de recursos clínicos.

El problema real no es cuándo reentrenar, sino qué actualizar



Covariate shift

Cambia $P(X)$: rangos, frecuencias, combinaciones

→ **Desactualiza el preprocesamiento (Stage 1)**

Concept drift

Cambia $P(Y|X)$: la regla que vincula X con Y

→ **Invalida el modelo predictivo (Stage 2)**



Práctica habitual: reentrenar todo el pipeline ante cualquier caída, lo que es costoso [2].

Pero una acción parcial puede bastar: solo transformar por cuantiles reduce el estadístico KS de 0.0559 a 0.0072 sin reentrenar [5].

Ningún trabajo previo decide qué etapa actualizar

Trabajo	Tipo de drift	Severidad	Pipeline 2 etapas	Recuperación	Costo	Política RL
DISDE [3]	✓	✗	✗	✗	✗	✗
SHIFT [4]	✓	✗	✗	✓	✗	✗
TableShift [1]	✗	✗	✗	✗	✗	✗
CARA [2]	✗	✗	✗	✓	✓	✗
Severity-Aware [5]	✗	✓	✗	✓	✓	✗
Self-Healing [6]	✗	✗	✗	✗	✓	✗
DARL (esta tesis)	✓	✓	✓	✓	✓	✓



La brecha

Diagnostican el drift o deciden cuándo reentrenar, pero tratan el pipeline como una sola pieza.

Shakhovska y Pukach piden como trabajo futuro adaptar "también al tipo de drift" [5].

Tanna propone integrar aprendizaje por refuerzo en la remediación [6].

Pregunta de investigación

¿Puede una política de aprendizaje por refuerzo elegir, a partir de señales de monitoreo, la actualización selectiva que maximiza la recuperación del rendimiento al menor costo computacional?



A1 · Defer

No intervenir si el costo no se justifica



A2 · Update features

Reajustar Stage 1 (f_ϕ)



A3 · Update model

Reentrenar Stage 2 (g_θ)



A4 · Retrain all

Reajustar ambas etapas

Objetivos de la investigación

Objetivo general: diseñar, implementar y evaluar DARL, un framework que aprende con RL sobre un POMDP [8] qué etapa del pipeline actualizar según el tipo y la severidad del drift, y cuantifica la recuperación y el costo de cada acción.

	OE1	Módulo de monitoreo: detectar y clasificar covariate shift y concept drift, y su severidad (PSI, KS, C2ST)	Parcial
	OE2	Formalizar la decisión como POMDP: 4 acciones y recompensa AUC–costo	Hecho
	OE3	Entrenar el agente (PPO [9]) con episodios de drift sintético en PhysioNet y Diabetes [1]	Demo
	OE4	Evaluar la política frente a una tabla de decisión empírica (AUC-ROC y costo relativo)	Solo PhysioNet

DARL funciona como un ciclo de decisión de seis módulos



↻ La recompensa (6) retroalimenta la política, que vuelve a decidir ante el siguiente escenario de drift (2).

Dos regímenes tabulares y drift sintético controlado

Dataset	Tarea	Variables dominantes	Prevalencia
physionet	Sepsis en las próximas 6 h	Numéricas fisiológicas	1.2 %
diabetes_readmission	Readmisión hospitalaria	Categóricas y discretas	42 %

Covariate numérico

Mezcla Beta–Bernoulli

Cada valor se reemplaza por una muestra Beta con probabilidad γ

Covariate categórico

Remuestreo marginal

$$p_{\gamma}(c) = (1-\gamma) \cdot p_0(c) + \gamma \cdot q(c)$$

Concept drift

Rotación de pesos (logit_reweight)

$\beta_i(\gamma) = \beta_i \cdot (1 - 2\gamma)$: sin relación en $\gamma = 0.5$, invertida en $\gamma = 1$

Severidades: leve 0.25 · moderada 0.60 · severa 0.90 — el tipo y la magnitud del drift son conocidos, lo que permite saber cuál era la acción correcta.

Simular concept drift realista fue un reto de investigación



v1 • Label flipping aleatorio

Es ruido, no un cambio de regla



v2 • Inversión por mediana

Mueve $P(X)$: es covariate disfrazado




v3 • logit_shift (amplificar)

No degrada el AUC: la relación sigue igual




v4 • logit_reweight (rotar pesos)

Degrada el AUC de forma ordenada con $KS = PSI = 0$



Ante concept drift, corregir X no sirve; reentrenar el modelo sí



0.346

AUC de A1, A2 y A2c con $\gamma = 1.2$ (idénticas)

0.663

AUC de A3 y A4 con $\gamma = 1.2$

0.000


Diferencia máxima entre A2 y A1: X nunca cambió

El agente decide con información parcial: POMDP + PPO



Observación o_t

Severidad estimada, PSI/KS/C2ST, caída de AUC/F1 y costos previos. El agente no ve $P(X)$ ni $P(Y|X)$ [8].



Política $\pi_\theta(a | o_t)$

PPO con MlpPolicy (SB3): espacio discreto pequeño ($|A| = 4$) y actualizaciones estables gracias al clipping [9], [10].



Recompensa

Premia recuperar AUC frente al estado sin mantenimiento y penaliza tiempo y memoria relativos a Retrain all.

$$r_t = \lambda_A \cdot (\text{AUC}_{\text{acción}} - \text{AUC}_{\text{drift}}) - \lambda_C \cdot (\frac{1}{2} \cdot T / T_{\text{all}} + \frac{1}{2} \cdot M / M_{\text{all}})$$

$$\lambda_A = 1.00 \cdot \lambda_C = 0.25 \cdot T = \text{tiempo} \cdot M = \text{memoria máxima}$$

Configuración de la demo

Algoritmo	PPO, MlpPolicy (Stable-Baselines3)
Acciones	4 discretas
Episodio	100 pasos de decisión
Evaluación	50 episodios determinísticos
Factor de descuento γ	0.95
Rollout / batch / épocas	64 / 32 / 5
Semilla	42

Reentrenar todo no siempre es la mejor decisión

Condición	Severidad	A1 Defer	A2 Feat.	A3 Model	A4 All	Óptima
Covariate	Leve	96.6	95.4	98.0	98.1	A1
Covariate	Moderada	90.6	91.8	96.6	96.7	A3
Covariate	Severa	84.9	89.7	96.1	95.7	A3
Concept	Leve	98.1	100.0	99.9	100.0	A2
Concept	Moderada	92.7	82.8	96.6	96.6	A1
Concept	Severa	86.3	82.6	100.0	99.7	A3
Cov. + Concept	Moderada	87.6	83.1	96.6	92.9	A3
Cov. + Concept	Severa	80.8	88.4	95.7	96.2	A3

% de recuperación = $\text{AUC de la acción} / \text{AUC base (0.7836)} \times 100$. Costo relativo: A1 0.00x · A2 0.12x · A3 0.45x · A4 1.00x.

Covariate shift moderado

A3: 96.6 %

A4: 96.7 %


55 %

menos costo con A3 (0.45x vs 1.00x) por 0.1 puntos menos de recuperación

La acción óptima cambia con el tipo y la severidad del drift.

La política PPO aprende a preferir actualizaciones parciales

Acciones elegidas en la evaluación final



5 000

decisiones evaluadas (50 episodios × 100 pasos)

0.0334



recompensa media por paso

3.34 ± 0.42

recompensa acumulada media por episodio

Defer y Retrain all: 0 %. Defer no recupera AUC; Retrain all paga el costo completo por una mejora marginal. Valida el ciclo POMDP, pero aún no demuestra superioridad.

Con drift combinado, la acción ideal depende del dataset



No existe una regla fija válida para todos los datasets: esto motiva aprender la política en lugar de programarla con umbrales.

Plan de validación: cómo sabremos si DARL funciona

- H1** Covariate shift: una acción parcial (A2/A3) recupera ≥ 95 % de lo que recupera A4, con menor costo
- H2** Concept drift: A3 $\approx$ A4 y ambas superan a A2; corregir X no aporta
- H3** La política aprendida obtiene más recompensa (recuperación – costo) que las reglas fijas en escenarios no vistos

Métricas

- Recuperación de AUC-ROC (frente a un oráculo)
- F1-score
- Costo: tiempo y memoria relativos
- Tasa de acción óptima y regret

Baselines

- Siempre / nunca reentrenar
- Umbral de Δ AUC; cada k días
- Clasificador supervisado de acciones
- Tabla de decisión empírica

Protocolo

- 2 datasets + caso temporal (fraude)
- Combinaciones tipo $\times$ severidad no vistas en entrenamiento
- 5 semillas e IC 95 %
- Misma definición de costo en todo

Limitaciones: de alcance y las que encontramos



De alcance (por diseño)

- Clasificación binaria tabular en batch; no streaming
- 2 datasets y 1 modelo principal (XGBoost)
- Se asumen etiquetas disponibles; en la realidad llegan tarde [7]
- Drift sintético; TableShift es shift estático, no temporal [1]
- Sin despliegue ni integración con MLflow/Airflow



Encontradas en el trabajo

- Demo PPO sintética y liviana: valida el flujo, no la convergencia
- Pasos independientes: falta dependencia temporal que justifique RL
- PPO nunca eligió Defer ni Retrain all (posible sesgo de λ_C)
- Diabetes: ninguna acción recupera bajo drift combinado
- Bugs: DriftInjector con variables con muchos ceros; make_logreg da AUC ≈ 0.51

Siguiente paso: validar DARL con drift temporal real (fraude)



IEEE-CIS Fraud Detection [14]

590 540

transacciones

182

días etiquetados

3.5 %

de fraude



Ventanas deslizantes de 7 días: en cada paso se miden señales, el agente decide y el modelo elegido enfrenta la ventana siguiente.

El test de Kaggle no trae etiquetas: toda la simulación ocurre dentro de los 182 días.

Agente secuencial

Estado ($3 \times 3 \times 3 = 27$)

severidad covariate S_X · caída ΔAUC · días desde el último reentrenamiento

Algoritmo

Q-learning tabular como sanity check, luego DQN [15]

Recompensa

$(AUC_{acción} - AUC_{defer} \text{ en la misma ventana}) - \lambda \cdot \text{costo}$

Por qué importa

La acción de hoy cambia el modelo de mañana: secuencialidad real que justifica RL

Plan de cierre en cuatro semanas

Semana 1

Semana 2

Semana 3

Semana 4

Go / no-go

- Corregir bugs de DriftInjector y make_logreg
- AUC oráculo para explicar Diabetes
- Fraude: curva de degradación del modelo congelado

Mapa de acción ideal

- Grilla $\gamma_{cov} \times \gamma_{con}$ con XGBoost y 5 semillas
- Drift en variables relevantes vs. irrelevantes
- Tabla ventana $\times$ acción precalculada (fraude)

Agente y baselines

- Q-learning $\rightarrow$ DQN $\rightarrow$ PPO
- Baselines: siempre/nunca reentrenar, umbral, cada k días, clasificador supervisado

Tesis

- Actualizar metodología (logit_reweight)
- Resultados con IC 95 %; Resumen y Abstract

Conclusiones



El tipo de drift determina la etapa a actualizar

Ante concept drift, corregir X no sirve; reentrenar el modelo sí.



El costo cambia la decisión

A3 iguala a A4 con 55 % menos costo; reentrenar todo nunca fue la óptima.



La política debe aprenderse

La acción ideal varía entre datasets: una regla fija no basta.

¿Preguntas?

Referencias

- [1] J. Gardner, Z. Popović y L. Schmidt, "Benchmarking distribution shift in tabular data with TableShift," NeurIPS, 2024.
- [2] A. Mahadevan y M. Mathioudakis, "Cost-aware retraining for machine learning," Knowledge-Based Systems, vol. 293, 2024.
- [3] T. T. Cai, H. Namkoong y S. Yadlowsky, "Diagnosing model performance under distribution shift," arXiv:2303.02011, 2023.
- [4] H. Singh et al., "Who experiences large model decay and why?," Proc. 42nd ICML, 2025.
- [5] K. Shakhovska y P. Pukach, "Severity-aware drift adaptation for cost-efficient model maintenance," AI, vol. 6, no. 11, 2025.
- [6] R. K. Tanna, "Self-healing ML pipelines," Preprints.org, 2025 (sin revisión por pares).
- [7] J. Gama et al., "A survey on concept drift adaptation," ACM Computing Surveys, vol. 46, no. 4, 2014.
- [8] L. P. Kaelbling, M. L. Littman y A. R. Cassandra, "Planning and acting in partially observable stochastic domains," Artif. Intell., vol. 101, 1998.
- [9] J. Schulman et al., "Proximal policy optimization algorithms," arXiv:1707.06347, 2017.
- [10] R. S. Sutton y A. G. Barto, Reinforcement Learning: An Introduction, 2.ª ed. MIT Press, 2018.
- [11] T. Chen y C. Guestrin, "XGBoost: A scalable tree boosting system," Proc. ACM SIGKDD, 2016.
- [12] M. A. Reyna et al., "Early prediction of sepsis from clinical data: the PhysioNet/CinC Challenge 2019," Crit. Care Med., vol. 48, no. 2, 2020.
- [13] B. Strack et al., "Impact of HbA1c measurement on hospital readmission rates," BioMed Research International, 2014.
- [14] IEEE Computational Intelligence Society y Vesta Corp., "IEEE-CIS Fraud Detection," Kaggle, 2019.
- [15] V. Mnih et al., "Human-level control through deep reinforcement learning," Nature, vol. 518, 2015.