Auditoría de DARL DQN Dummy v4

Recorrido del notebook, oportunidades de A3 y diagnóstico del 95 %

Alcance y datos

Se verificaron los bloques de código de `kaggle/dqn-dummy/v4/input/main.ipynb`, los ocho CSV del resultado principal y las gráficas usadas abajo. La corrida registra 1 552 210 filas de PhysioNet/Computing in Cardiology Challenge 2019 y 40 336 pacientes (Reyna et al., 2020). Las siete entradas son HR, O2Sat, Temp, SBP, MAP, DBP y Resp. El objetivo de XGBoost es `y_dummy`, una etiqueta artificial construida con un score de vitales y ruido determinista del 5 %; `SepsisLabel` solo estratifica las particiones. Por tanto, la AUC de este ensayo no mide detección clínica de sepsis.

Notebook, de entrada a resultado

Bloque / recibe	Proceso y produce
Carga y partición: parquet, patient_id, ICULOS, signos vitales y SepsisLabel	Ordena por paciente/tiempo, aplica forward-fill causal, separa pacientes A (70/15/15) y B (60/20/20); cada segmento B se divide en pacientes de actualización/evaluación. Construye `y_dummy`.
Replay y pipeline: pacientes, días y roles	Simula 200 camas (100 update, 100 eval) por 16 días. XGBoost inicial usa 60 árboles; mediana/IQR y clipping a $[-2, 2]$. A1 no cambia; A2 recalibra transformación; A3 reentrena XGBoost; A4 hace ambas cosas.
Drift y observación: replay y calendario	`inject` desplaza los vitales (covariate), cambia la regla de `y_dummy` (concept), o aplica ambos. KS, PSI y AUC se cuantizan en categorías; se concatenan las últimas tres observaciones (estado de 30 valores).
DQN, reward y evaluación	Double DQN estima cuatro valores Q con una red 30–128–128–4, epsilon-greedy, replay FIFO, Huber y red target. Al actuar el día d, la recompensa se revela con la AUC de evaluación en $d+1$, menos costo temporal normalizado. El retorno suma 15 recompensas válidas por episodio.

Una decisión completa: concept, día 7

Antes de elegir: el estado de día 7 incluye KS = 0,0687, PSI = 0,0202, AUC actual = 0,8616 y su historial categorizado. Como KS/PSI están debajo de 0,10 y AUC encima de 0,85, la codificación todavía representa señales bajas/altas aunque el concepto ya deriva ($u = 0{,}45$). Los valores almacenados fueron $Q(A1) = 1{,}5023$, $Q(A2) = 1{,}4581$, $Q(A3) = 1{,}4218$, $Q(A4) = 1{,}4546$; greedy selecciona A1. Tras la decisión, la AUC del día 8 cae a 0,8101; costo = 0,000000664, reward = 0,810063.

Lo que solo conoce la auditoría posterior: calcula, fuera de la política, las cuatro alternativas desde el mismo pipeline y datos de actualización del día 7, y mide cada una sobre la evaluación del día 8. Encuentra $U(A3) = 0{,}875907$, $U(A1) = 0{,}810063$ y regret = 0,065844. El agente no recibe el oracle ni la AUC futura. **Cautela temporal:** el código sí calcula la AUC de evaluación del día actual para formar la observación antes de actuar; no implementa un retraso explícito de esa etiqueta actual. Si el supuesto de tesis exige etiquetas retrasadas, hay que corregir el entorno antes de presentar v4 como fiel a ese supuesto.

Oportunidades donde A3 fue el oracle de un paso

Escenario	Día	DQN	$U(A3)$	U elegida	Regret
concept	6	A1	0,8783	0,8616	0,0168
concept	**7**	**A1**	**0,8759**	**0,8101**	**0,0658**
concept	8	A3	0,8792	0,8792	0,0000
concept	9	A1	0,8855	0,8745	0,0110
concept	14	A1	0,8821	0,8564	0,0257
concept	15	A1	0,8943	0,8523	0,0420
combined	**9**	**A2**	**0,8832**	**0,8371**	**0,0460**
combined	10	A4	0,8783	0,8703	0,0080
combined	12	A2	0,8804	0,8378	0,0426
combined	**13**	**A4**	**0,8862**	**0,8768**	**0,0094**

Tres casos: (1) Concept día 7: $Q(A1) > Q(A3)$, pero la información categorizada aún no refleja la caída suficiente; es la mayor de estas pérdidas. (2) Combined día 9: $Q(A2) = 1{,}1358$ supera $Q(A3) = 1{,}0149$, así que el DQN elige recalibrar features; el oracle inmediato favorece A3 por 0,0460. (3) Combined día 13: el agente elige A4 ($Q = 0{,}9561$); A3 supera su utilidad solo por 0,0094. Es una diferencia pequeña y el regret queda bajo 0,01. El oracle es de un paso, no una política óptima de horizonte largo.

Métodos, comparadores y lectura de los CSV

La partición por paciente evita repartir horas de una misma persona entre ajuste y evaluación. Se comparan A1–A4, DQN, aleatoria y una heurística. La heurística usa umbrales KS/PSI/AUC relacionados con los cortes de observación; no debe describirse como acceso a señales distintas. A1 es el control sin mantenimiento; A2 y A3 aíslan transformación/modelo; A4 es la actualización completa. XGBoost es el modelo de clasificación (Chen y Guestrin, 2016); DQN aprende valores de acción mediante Q-learning profundo y Double DQN (Mnih et al., 2015; van Hasselt et al., 2016).

CSV	Filas	Hallazgo / límite
`actions.csv`	420	60 acciones por cada una de 7 políticas; DQN registra acción solicitada/ejecutada, Q, AUC, costo y reward.
`action_audit.csv`	60	Las cuatro utilidades y regret están presentes; oracle elige A3 10 veces; coincidencia exacta DQN–oracle 49/60 = 81,7 %.
`training_history.csv`	1000	100 validaciones (cada 10 episodios), epsilon, retorno y acuerdos; faltantes en episodios sin validación son esperados.
`policy_comparison.csv`	28	7 políticas × 4 escenarios, 15 rewards válidos cada una; una semilla, sin intervalos de incertidumbre.
`calibration.csv`	6	3 rates por tipo; 0,25 IQR/día y 0,15 unidades/día son los rates más lentos que califican.
`daily_metrics.csv`	448	AUC completa en 16 días; 28 rewards faltantes corresponden al día terminal, sin acción siguiente.
`stage_calendar.csv`	64	Cuatro rampas de 16 días; combined inicia covariate en día 5 y concept en día 7.
`drift_dia1_vs_dia16.csv`	2	Resumen auxiliar de covariate/concept; KS día 1–16 mezcla inyección y recambio de cohortes.

Retorno A1/A2/A3 (y DQN): covariate 11,794/13,776/12,606 (13,843); concept 11,369/11,052/13,271 (13,382); combined 11,700/11,826/12,556 (13,467). Los costos acumulados DQN son 0,097/0,095/0,164. En stable, DQN coincide con A1. Una corrida no permite generalizar estadísticamente.

Proveniencia gráfica: el manifiesto declara 18 rutas (9 PNG + 9 SVG), pero el directorio tiene 17 PNG y ningún SVG; incluye variantes 04a/b y 05a/b, 07a/b y dos figuras del notebook auxiliar. No asumir que son 18 pares exportados.

Estabilidad: evidencia, interpretación y próximo paso

El gate exige variación del retorno $\leq 5\,\%$ y acuerdo exacto $\geq 95\,\%$. v4 obtuvo 1,47 % y 85 % (51/60): pasó el primero y falló el segundo. Ningún checkpoint alcanzó 95 % (máximo 90 %); los cinco finales fueron 35 %, 38 %, 87 %, 83 %, 85 %. Se agotaron 1000 episodios y 14 937 actualizaciones.

No se demostró una causa única. La discretización puede retrasar concept: en días 3–7, KS/PSI quedan bajo sus cortes y la AUC no cruza 0,85 hasta el día 8. La política seleccionada es del episodio 940, pero el gate compara 990 con 1000; 85 % no mide estabilidad alrededor del checkpoint reportado. Siguiente paso: medir checkpoints vecinos por escenario y varios bloques consecutivos, registrar márgenes Q/regret, repetir semillas y mantener B-test intacto. Más episodios o bajar el umbral no prueban convergencia.

Gráficas: observación, valores Q y entrenamiento

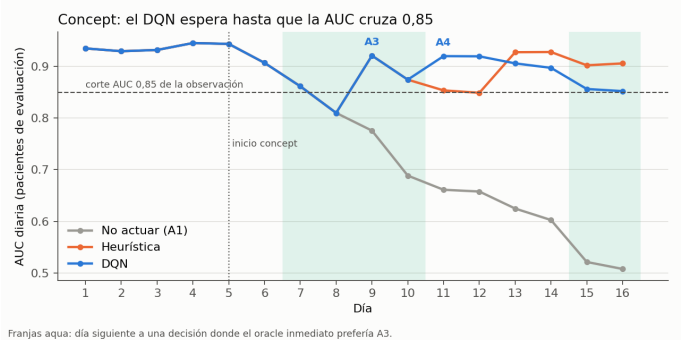


Figura 1: Concept: el DQN selecciona A3 tras cruzar el corte de AUC 0,85. La trayectoria A1 sin acción cae; la franja verde identifica días posteriores a oportunidades oracle A3.

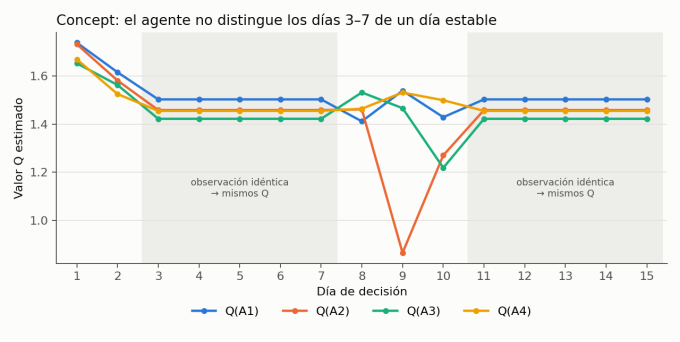


Figura 2: Los Q son iguales en días 3–7 porque las señales caen en las mismas categorías; en día 7 $Q(A1)$ es mayor que $Q(A3)$.

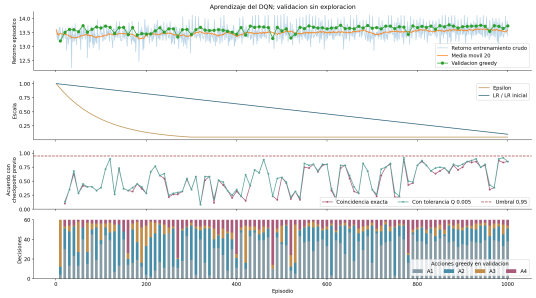


Figura 3: El retorno greedy se estabiliza antes que las acciones: el acuerdo exacto (panel 3) no llega al umbral rojo de 0,95 en los checkpoints finales.

Fuentes: `main.ipynb`; CSV en `kaggle/dqn-dummy/v4/outputs/`; figuras de auditoría en `kaggle/dqn-dummy/v4/outputs/analisis/`. El documento enlazado `C:/Users/jeffr/GitHub/tesis-darl/plan/diagnostico_a3_v4.md` no está disponible en este equipo; conclusiones verificadas contra artefactos locales.