DQN Dummy v4: cómo decide el agente y por qué desaprovecha A3

Explicación del notebook, decisión trazada y oportunidades perdidas

Brigitte Dayane Rojas Jeffrey Antonio Monja

Proyecto de tesis DARL

Corrida `jeffreyamc/darl-dqn-dummy-v4` · semilla 42 · checkpoint 940

Pregunta y mensaje principal

Pregunta de v4

Cuando el cambio estadístico crece **gradualmente cada día**, ¿aprende el agente *cuándo* actuar y *qué* etapa del pipeline actualizar?

Funciona

- Covariate: coincide con el oracle en **15/15** decisiones.
- Con drift, recupera la AUC de 0,77–0,80 a **0,90–0,93**.
- No actúa cuando no hay cambio.

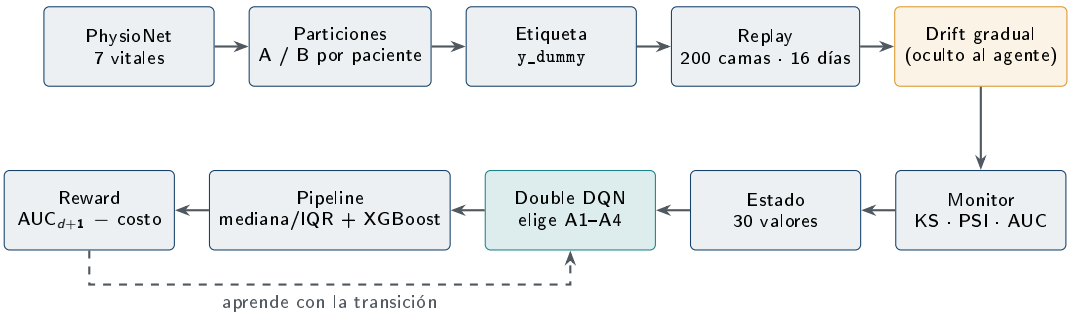
Falla

- Aprovecha solo **1 de 10** oportunidades de A3.
- Llega tarde al concept drift.
- Frente a la heurística: empata o pierde.

Hallazgo central

Mientras la AUC está sobre 0,85, un día con concept drift produce **la misma observación** que un día estable: el agente no puede distinguirlos.

El notebook por bloques



Cada día: el monitor mide el pipeline actual → el agente elige una acción al cierre → el día siguiente revela la recompensa.

Datos, particiones y etiqueta artificial

Preparación de PhysioNet

- 40.336 pacientes y 1,55 M filas horarias.
- 7 vitales: HR, O2Sat, Temp, SBP, MAP, DBP y Resp.
- Faltantes: último valor del *mismo* paciente (sin información futura).

Particiones disjuntas por paciente

- Hospital A: 70/15/15 $\rightarrow$ modelo inicial.
- Hospital B: 60/20/20 $\rightarrow$ entrenar, validar y probar el agente.
- En B: pacientes de *update* (para actualizar) y de *eval* (para medir la AUC).

Etiqueta `y_dummy`

- Score lineal de los 7 vitales normalizados.
- $y = 1$ si el score supera la mediana; luego se invierte el 5 % al azar.
- Prevalencia 0,47. **No es la sepsis real**.

Simulación temporal

- 100 camas de update y 100 de eval.
- Cuando un paciente termina, entra otro.
- 2.400 filas por día y rol, durante 16 días.

Pipeline, acciones y drift gradual

Pipeline de dos etapas: normalización mediana/IQR recortada a ± 2, seguida de XGBoost (AUC 0,944 en A-test).

Acción	Qué hace	Costo
A1	No hacer nada	0
A2	Recalcular mediana e IQR	0,009
A3	Reentrenar XGBoost	0,040
A4	A2 + A3	0,050

Costo = 0,05× segundos / segundos de A4.

Drift gradual (empieza el día 5)

- **Covariate**: desplaza los vitales 0,25 IQR por día.
- **Concept**: cambia 0,15 por día los pesos que definen la etiqueta.
- **Combined**: ambos; el concept empieza 2 días después.

Las velocidades se calibran con B-train: caída $< 0{,}05$ el primer día, $> 0{,}15$ tras 6 días y recuperación $> 0{,}10$ al actuar.

Estado, recompensa y Double DQN

Estado: 30 valores

- Por día: KS máx., PSI máx. y AUC, cada uno en 3 categorías.
- Cortes de la AUC: $< 0{,}65$ · 0,65–0,85 · $\geq 0{,}85$.
- 10 valores por día $\times$ 3 días.

Recompensa

$$r_d = \mathrm{AUC}_{d+1} - \lambda \frac{t_a}{t_{A4}}$$

Donde: AUC_{d+1} es la AUC del día siguiente en pacientes eval; t_a son los segundos de la acción; t_{A4} es la mediana de A4; $\lambda = 0{,}05$.

Double DQN (idea)

- La red estima un valor Q por acción: la recompensa futura esperada.
- Se elige la acción con mayor Q.
- La red *online* **elige** la acción siguiente y una copia congelada (*target*) la **valora**. Eso reduce la sobreestimación.

Entrenamiento

- Hasta 1000 episodios; 6 de cada 7 con drift.
- Día de inicio (3–7) y velocidad sorteados.
- Se elige el checkpoint 940 por validación.

Resultado global en B-test

Escenario	DQN	Heurística	No actuar (A1)	A3 fija
Stable	14,106	14,106	14,106	13,342
Covariate	**13,843**	13,807	11,794	12,606
Concept	13,382	**13,405**	11,369	13,271
Combined	**13,467**	13,422	11,700	12,556

Retorno = suma de 15 recompensas diarias (`policy_comparison.csv`).

Lo positivo

Supera claramente a no actuar y a cualquier acción fija en los tres escenarios con drift.

Lo que no se puede afirmar

Las diferencias con la heurística ($\leq 0{,}045$) son de una sola corrida; no superan el ruido diario de la AUC.

Una decisión completa: concept, día 7

Lo que sabía el agente al decidir

- KS máx. 0,069 → *bajo*.
- PSI máx. 0,020 → *bajo*.
- AUC del día 0,862 → *alta* ($\geq 0{,}85$).
- Días 5 y 6 iguales: AUC 0,944 y 0,907.

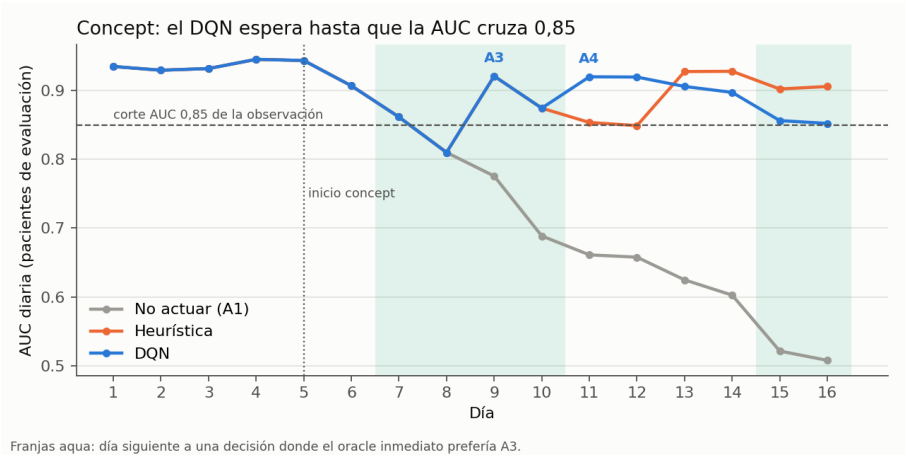
Q: A1 **1,502** · A2 1,458 · A3 1,422 · A4 1,455
⇒ elige **A1**.

Lo que se conoce después (auditoría)

- Severidad oculta del concept: 0,45.
- AUC del día 8 con A1: **0,810**; costo ≈ 0; reward 0,810.
- Oracle (las 4 acciones sobre el mismo día 8): A1 0,810 · A2 0,786 · **A3 0,876** · A4 0,863.
- *Regret* = 0,066, el mayor del experimento.

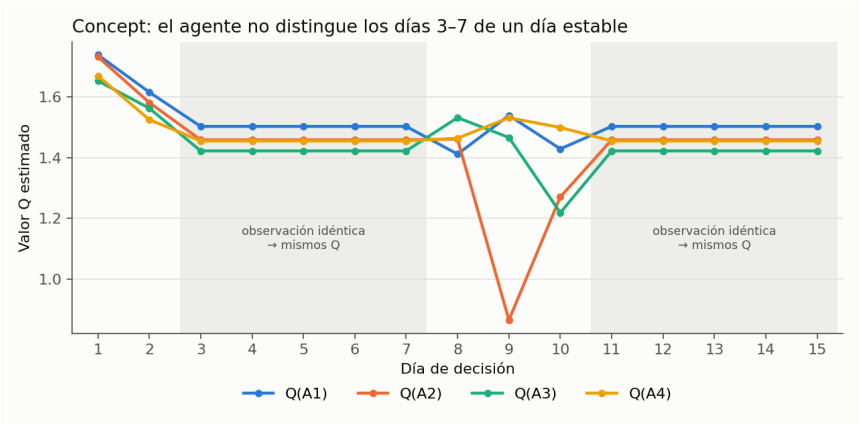
Los valores Q son **exactamente iguales** a los de un día del escenario stable.

Concept: el agente espera hasta que la AUC cruza 0,85



Sin actuar, la AUC cae de 0,94 a 0,51. El DQN y la heurística siguen la misma curva hasta el día 8: ninguno actúa mientras la AUC está sobre el corte. En los días 14–15 vuelve a caer y el DQN no reacciona.

No es que decida esperar: no puede ver la diferencia



En los días 3–7 y 11–15 los valores Q quedan planos: la entrada es la misma que en un día estable. Q(A3) solo supera a Q(A1) el día 8, cuando la AUC pasa a la categoría media.

Tabla de oportunidades: días donde el oracle prefería A3

Escenario	Día	Elegida	Util. A3	Util. elegida	Regret	AUC obs.	KS / PSI
Concept	6	A1	0,878	0,862	0,017	0,907	0,07 / 0,02
Concept	7	A1	0,876	0,810	**0,066**	0,862	0,07 / 0,02
Concept	8	A3	0,879	0,879	0,000	0,810	0,06 / 0,03
Concept	9	A1	0,885	0,874	0,011	0,921	0,07 / 0,02
Concept	14	A1	0,882	0,856	0,026	0,897	0,08 / 0,05
Concept	15	A1	0,894	0,852	0,042	0,856	0,09 / 0,05
Combined	9	A2	0,883	0,837	**0,046**	0,887	0,23 / 0,14
Combined	10	A4	0,878	0,870	0,008	0,846	0,23 / 0,22
Combined	12	A2	0,880	0,838	0,043	0,890	0,35 / 8,19
Combined	13	A4	0,886	0,877	**0,009**	0,847	0,26 / 0,15

Aprovecha 1 de 10 oportunidades. *Regret* total en las 9 restantes: **0,27**.

Tres casos, tres tipos de fallo

Concept, día 7

No ve el problema.

La AUC (0,862) sigue sobre 0,85, así que el estado es igual a un día estable. Ahí A3 casi siempre pierde: cuesta 0,04 y, sin drift, reentrenar con un día baja la AUC (0,940 $\rightarrow$ 0,932).

Regret 0,066.

Combined, día 9

Confunde el tipo de cambio.

KS 0,23 y PSI 0,14 parecen covariate, y la AUC (0,887) aún es alta. Elige A2 (Q 1,136 frente a 1,015 de A3), pero el concept ya va en 0,45 y solo A3 lo corrige.

Regret 0,046.

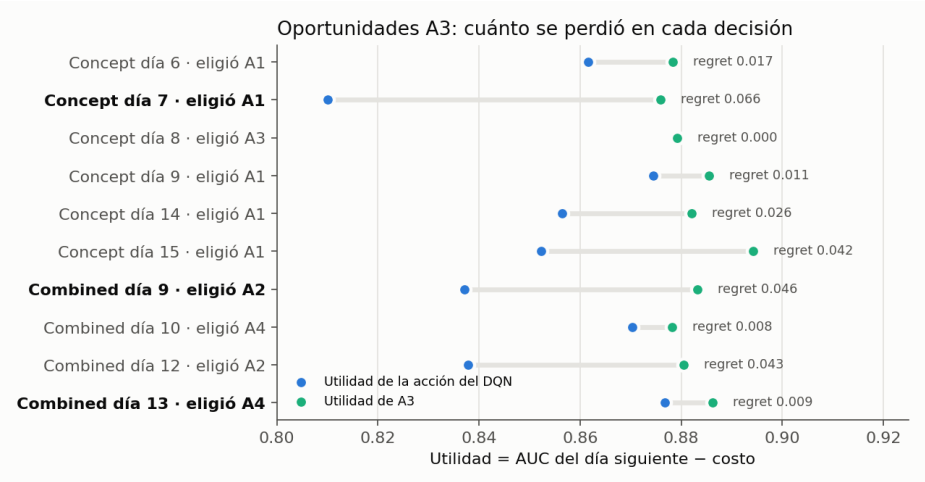
Combined, día 13

Acierta, pero paga de más.

La AUC (0,847) bajó del corte y elige A4 (Q 0,956). A4 incluye A3 y logra la misma AUC ($\approx$ 0,929); la pérdida es solo la diferencia de costo entre A4 y A3.

Regret 0,009.

Cuánto se perdió en cada oportunidad



Las pérdidas grandes ($\geq 0{,}04$) ocurren cuando la AUC aún está sobre 0,85 (concept 7 y 15) o cuando las señales de covariate tapan el concept (combined 9 y 12).

Lo que muestra el entrenamiento

A3 se usa cada vez menos

- Elección de A3 en entrenamiento: **21 %** → **7 %**.
- En validación: de ∼14 a ∼3–5 decisiones de 60.
- En los estados donde se prueba, A3 casi siempre pierde, así que el agente deja de elegirla.

La política no se estabiliza

- Coincidencia entre checkpoints consecutivos: 0,37–0,74 por bloque de 100 episodios.
- Baja hasta **0,35** cerca del final.
- Gate `validation_converged`: **no cumplido** (85 % frente a 95 %).

Además

El costo medido de A3 varía entre 0,036 y 0,081 según la CPU de Kaggle: el reward incluye ruido del hardware.

Posibles explicaciones

1. **Estados indistinguibles** (la más respaldada). El corte de AUC en 0,85 junta los días con concept temprano y los días estables. Comprobado: los valores Q son idénticos.
2. **Señales mezcladas en combined.** KS y PSI solo miden el cambio de medición; cuando aparecen, el agente atribuye la caída a covariate.
3. **A3 se refuerza poco.** Se prueba sobre todo en estados donde pierde, y su uso cae del 21 % al 7 %.
4. **Ruido en el reward.** La variación del costo de A3 es mayor que muchas de las diferencias que el agente debe aprender.

Experimento sin entrenar: ¿actuar antes con A3 mejora el episodio?

Mismo código del v4, **20 replays** de B-test, costo fijo por acción y **ningún DQN entrenado**. Se cambia solo la regla de decisión.

Diferencia vs. heurística v4	Corte 0,90	Caída AUC $\geq 0{,}03$	Oracle miope*	Periódica (A3 c/3 días)
Stable	0,000	0,000	0,000	$-0{,}314$
Covariate	$-0{,}009 \pm 0{,}012$	$-0{,}029 \pm 0{,}019$	$+0{,}023$	$-0{,}103$
Concept	$+0{,}137 \pm 0{,}021$	$+0{,}116 \pm 0{,}022$	$+0{,}166$	$+0{,}036$
Combined	$+0{,}140 \pm 0{,}037$	$+0{,}114 \pm 0{,}047$	$+0{,}202$	$-1{,}105$

* Usa etiquetas futuras: es solo una referencia. Valores: media de diferencias pareadas $\pm$ IC 95 %.

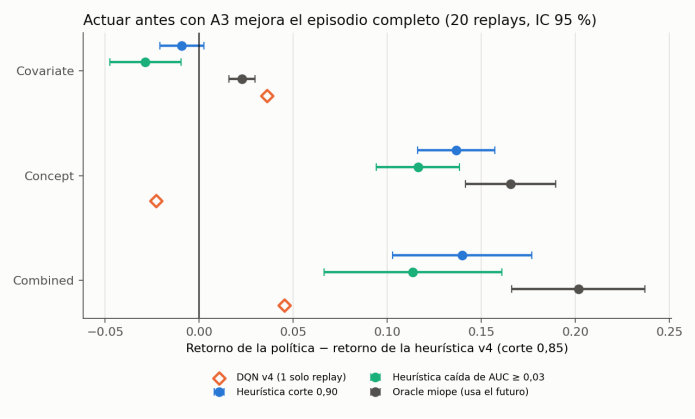
Lectura

Con corte 0,90 la primera A3 llega el día 7 (antes, el 8) y gana en **20/20** replays de concept. Captura el 83 % de la ventaja del oracle. Sin drift no genera falsas alarmas.

Límite

Los cortes 0,90 y 0,03 se eligieron a mano y se midieron en B-test. Para la tesis hay que elegirlos en B-val.

Una corrida no basta; la información sí está en la AUC



- En el **mismo replay** del v4, la heurística 0,90 supera al DQN en concept (13,555 vs. 13,382) y en combined (13,555 vs. 13,467).
- Entre replays, la diferencia pareada varía 0,04–0,10: las diferencias DQN–heurística del v4 ($\leq$ 0,045) no son concluyentes.

Evidencia que falta y próximos pasos

Evidencia que falta

- **Ya respondido**: actuar antes con A3 sí mejora el episodio completo (experimento sin entrenar).
- **Elegir los cortes en B-val** y confirmar en B-test.
- **Confirmar la explicación 1 con el DQN**: reentrenarlo con observación continua y evaluarlo en los 20 replays.

Propuesta para v5

- Observación con métricas **continuas**, última acción y días desde la última actualización.
- **Costo fijo** por acción en lugar del tiempo medido.
- Evaluación con varias semillas, IC 95 % y baseline periódico.
- Etiqueta con 1 día de retraso, como en la tesis.

Los signos vitales son reales; la etiqueta y el drift son sintéticos. No es una validación clínica.